


基于 xv6 的内核功能扩展与性能量化评估

- 操作系统课程设计结题报告
- 姓名：袁善
- 学号：20231072030
- 日期：2026年6月20日

一、项目摘要

- 项目背景与目标：
 - 作为 MIT 经典的教学操作系统，xv6-riscv 展现了简洁的 Unix 内核结构与 RISC-V 虚拟内存机制。然而，原生 xv6 针对教学做了极简化处理，缺乏按需分配、写时复制（COW）、轻量级线程、文件内存映射（mmap）等现代内核特性，难以应对高并发或算力密集型应用。
 - 基于此，本项目旨在**基于 MIT xv6-riscv**，在完成课程要求功能的前提下，引入部分现代 Unix/Linux 内核设计思想，**拓展 xv6 内核的功能边界并验证其在真实负载下的表现**。
- 团队信息与分工：本项目由袁善（学号 20231072030）单人独立完成。
- 开发环境：宿主机 Windows 11 + VSCode (SSH 远程连接)；目标机 Ubuntu 22.04 LTS；编译：`riscv64-linux-gnu-gcc`；模拟器：QEMU 7.2.0 (`qemu-system-riscv64`)。
- 工作概述
 - 功能实现**：共支持 37 个系统调用（其中**增量实现 16 个**）。包括内核级堆分配器（`kmalloc/kfree`）、按需分页（Lazy Allocation）、写时复制（COW Fork）、文件内存映射（`mmap/munmap`）、FCFS 与 RR 动态调度切换、轻量级线程（`clone`）、用户态快速同步互斥体（`futex`）以及信号量、异步定时器（Alarm）、软链接（`Symlink`）等模块。
 - 功能验证**：系统通过**增量的 20 项单元测试**、**xv6 原生 `usertests` 集成测试**，在 **grind 压力测试**下持续运行，未发生内核 Panic 或死锁。**达到课程标准**。
 - 性能评估**：移植极简 Transformer 推理引擎 `llama.c` 并加载 **stories260K** 模型，针对**多核并行能力、同步原语效率及存储映射机制设计**对比实验，量化评估内核相关子系统的实际开销。



二、项目完成情况

- 项目仓库地址：<https://github.com/yuuichi33/OS>

2.1 功能实现

本项目共支持 **37 个系统调用**，其中 21 个为原生系统调用，**16 个为本项目增量设计与实现**。

模块	xv6 已实现功能	本项目扩展实现
系统启动	M→S 态切换、内核加载、栈初始化、启动日志	—
中断与异常	时钟中断、键盘输入、ecall 系统调用	缺页异常处理（Lazy/COW/VMA）、用户态异常分类拦截（scause 2/13/15 诊断）
内存管理	物理页分配、Sv39 虚拟内存	kmalloc/kmfree 内核堆分配器、按需分页、COW Fork、mmap/munmap
进程管理	PCB、fork/exec、RR 调度	FCFS 非抢占调度（RR/FCFS 动态切换）、waitpid（WNOHANG）、Semaphore 信号量、Alarm 异步定时器
文件系统	目录文件操作、路径解析、重定向、mkfs	lseek（SEEK_SET/CUR/END）、Symlink 软链接
用户程序	ELF 加载、Shell、管道	ps 命令（getprocs 系统调用）、异常隔离（用户态崩溃不 panic）
扩展功能	—	alarm、COW Fork、mmap/munmap、clone 线程、futex 用户态锁

2.2 交付物

- 14 周提交进度报告，含技术方案、分工方案。
- 结题报告PDF，内容包括项目概述，技术方案，详细实现，系统运行功能测试，创新点，总结与展望等内容。
- 汇报PPT、可运行源码及文档。

三、项目内容

3.1 系统设计目标与技术选型

xv6 是一个面向教学的 Unix 风格操作系统，其代码结构清晰、模块划分合理，完整实现了进程管理、虚拟内存管理、文件系统、系统调用和异常处理等核心机制。

本项目基于 riscv 架构的 **xv6** (<https://github.com/mit-pdos/xv6-riscv>) 进行增量式开发，重点参考 Linux 和开源项目 Re-XVapor (<https://github.com/sandyyyz/Re-XVapor>) 以及 MIT 6.S081。项目拟在保持 xv6 原有体系结构稳定性的前提下，逐步扩展其功能，实现课程设计要求的操作系统关键机制，并在此基础上引入部分现代 **Unix/Linux** 内核设计思想，提高系统的完整性与可扩展性。

处理器架构与内核基准决策依据

- RISC-V 架构指令设计简洁**：规避了 x86 繁重的历史兼容包袱，RV64 寄存器与控制状态寄存器（CSRs）设计清晰，极大简化了上下文切换与 Trap 处理的汇编实现。

- **特权级与分页规范**：具备明确的 U/S/M 特权级划分，配合标准的 Sv39 三级页表，能够较好地映射进程隔离、虚存管理等操作系统核心概念。
- **xv6 体量精简，抽象完整**：相比复杂的 Linux 内核，xv6 代码体量适中，且完整保留了 Unix 的核心抽象（PCB、VM、VFS、Syscall），为后续渐进式扩展 COW、Lazy Allocation、clone 线程等现代内核特性留出了充足的改造空间。


平台技术选型与硬件模拟合理性依据

系统采用 **QEMU virt 平台**（配合 OpenSBI 固件）作为开发运行环境，其合理性如下：

- **特权级切换**：标准固件 OpenSBI 运行于 M-Mode，通过 mret 降权至 S-Mode 引导内核，从而能够规范化地配置 sstatus 等监管态寄存器的特权级行为。
- **页表机制对齐**：QEMU MMU 硬件级支持 Sv39 三级页表走表，对未映射或只读写企图能精准触发缺页异常（scause 12/13/15），为 Lazy 分配、COW 及 mmap 的延迟装载提供标准的硬件反馈。
- **中断与多核并发**：通过仿真 CLINT/PLIC 提供稳定的时钟（用于调度与 sigalarm）与外设中断；利用 -smp 模拟多核并发环境，用以验证 clone 线程的物理页共享与 futex 的多核同步机制。

3.2 系统总体架构

系统采用经典的分层式设计。整体运行环境由 QEMU、OpenSBI 和 xv6 内核组成。



- **QEMU**：提供 RISC-V 虚拟硬件环境（`-machine virt`，4 核，128MB 内存）
- **OpenSBI**：完成机器态（M-Mode）到监管态（S-Mode）的初始化和特权级切换
- **xv6 内核**：负责 CPU、内存、磁盘、中断等全部资源的管理和系统服务
- **系统调用层**：提供用户态与内核态的交互接口（共 37 个系统调用）
- **用户空间**：运行 Shell 和应用程序

3.3 子系统设计与实现

3.3.1 系统启动（Bootloader）

1. 启动与特权切换控制流

```
QEMU → OpenSBI (M-mode 初始化与硬件配置)
      → 执行 mret 切换至 S-mode
      → entry.S (各 CPU 核分配独立的内核栈)
      → start.c (配置监听寄存器与中断委托)
      → main.c (主 CPU 初始化内存、进程、文件系统等，激活次 CPU)
      → scheduler() → 调度 init 进程 → 启动用户态 Shell
```

2. 启动日志 系统在 QEMU 中稳定启动并进入 Shell，启动过程可复现，无异常重启：

```
xv6 kernel is booting

hart 1 starting
hart 2 starting
hart 3 starting
$ _
```

此部分完全复用 xv6 已实现功能。

3.3.2 中断与异常处理 (Trap & Interrupt)

xv6 采用基于 **Trap** 的统一异常处理框架。所有系统调用、异常和中断最终均通过 Trap 机制进入内核。RISC-V 架构中，scause 寄存器标识中断/异常类型：

scause	类型	说明
8	系统调用	ecall 指令触发
2	非法指令	执行损坏指令
12	指令缺页	执行无权限内存
13	读缺页	读取未映射/无权限地址
15	写缺页	写入只读/未映射地址

1. 异常分发控制流

```
用户态运行 → 中断/异常 → trampoline.S → usertrap()
├─ scause == 8 → 系统调用 → syscall() 分发
├─ devintr != 0 → 硬件中断 (时钟/键盘/磁盘)
│   └─ which_dev == 2 → 时钟中断 → alarm 检测
└─ 其他异常 → 分类拦截
    ├─ scause 2 → 非法指令 → 打印诊断 → Kill 隔离
    ├─ scause 13 → 读段错误 (Load Page Fault)
    │   └─ VMA 区间 → mmap 按需调页
    │       └─ 堆区间 → Lazy Allocation
    ├─ scause 15 → 写段错误 (Store Page Fault)
    │   └─ VMA 区间 → mmap 按需调页
    │       └─ PTE_COW → COW 分裂
```

```

└── 堆区间 → Lazy Allocation
└── 其他 → 打印诊断信息 → setkilled(p)

```

2. 设计与实现细节

- 修改 trap.c 中的 usertrap(), 实现对非法指令 (scause == 2) 与内存越界读写 (scause 13/15) 的分类识别。
- 当发生无法通过缺页机制修复的异常时, 内核打印错误地址与指令并强制结束该进程 (exit(-1)), 从而保证内核与其他并发进程正常运行不发生 Panic。

3. 核心代码 (kernel/trap.c):


```

void usertrap(void) {
    // ...
    if(r_scause() == 8){
        // 系统调用
        p->trapframe->epc += 4;
        intr_on();
        syscall();
    } else if((which_dev = devintr()) != 0){
        // 硬件中断 alarm 检测
        if(which_dev == 2 && p->alarm_interval > 0) {
            p->alarm_ticks++;
            if(p->alarm_ticks == p->alarm_interval) {
                *p->alarm_tf = *p->trapframe; // 备份现场
                p->trapframe->epc = p->alarm_handler; // 重定向
            }
        }
    } else {
        // 用户态异常分类拦截
        uint64 scause = r_scause();
        uint64 stval = r_stval();
        uint64 sepc = r_sepc();
        if(scause == 13 || scause == 15) {
            // 缺页处理: VMA / Lazy / COW
            // ...
        } else {
            // 非法指令等 → 打印诊断 → Kill
            printf("[Exception] Process %d killed: scause=%p\n", p->pid, scause);
            setkilled(p);
        }
    }
    if(killed(p)) exit(-1);
}

```

3.3.3 内存管理 (Memory Management)

xv6 采用页式内存管理。在原有 4KB 物理页框分配器 (kalloc/kfree) 与 Sv39 页表的基础上, 本项目重构并扩展了内存管理结构:



A. 内核堆分配器 (kmallocc/kmfree)

为了给信号量、线程参数及定时器备份等模块提供内核动态内存支持，本项目在底层的 kalloc 之上构建了一个字节级动态内存分配器 kmallocc 与 kmfree。

1. 核心数据结构 (kernel/kallocc.c):

```
// 内存块首部： 每个分配块在数据区之前携带元信息
struct kmem_header {
    uint64 size;           // 内存块大小（不含首部，单位：字节）
    struct kmem_header *next; // 指向下一内存块（隐式空闲链表指针）
    int is_free;           // 是否空闲（1：空闲，0：已分配）
};

// 全局堆管理器： 管理所有内核堆内存块
struct {
    struct spinlock lock;      // 多核并发互斥锁
    struct kmem_header *head; // 隐式空闲链表头指针
} kmallocc_mem;
```

2. 算法控制流：First-Fit 分配 + 相邻空闲块合并 (Coalesce)

- 分配 (kmallocc)：将请求大小对齐至 8 字节。持锁遍历隐式空闲链表，寻找首个 is_free=1 且 size >= 请求大小的块 (First-Fit 策略)。

- **Split (切分)**: 若当前块大小超出请求大小与 Header 大小之和, 将其分裂为前后两块, 后半段重新初始化为空闲块插入链表。
- 若无满足条件的空闲块, 则释放锁并调用底层 `kalloc()` 申请新页, 将其挂入链表头部, 重新分配。
- **释放 (kmfree)**: 将目标块标记为 `is_free=1`。随后扫描整个链表, 检测物理地址相邻的空闲块 (当前块末尾地址 == 下一个块起始地址), 若连续则合并 (Coalesce), 防止碎片累积。若某块独占整张物理页, 则归还给物理页分配器。

3. 核心代码 (`kernel/kalloc.c`):

```
void* kmalloc(uint64 size) {
    if(size == 0) return 0;
    size = (size + 7) & ~7; // 8 字节对齐
    acquire(&kmalloc_mem.lock);
    struct kmem_header *curr = kmalloc_mem.head;
    // First-Fit: 遍历空闲链表, 定位首个满足大小的块
    while(curr) {
        if(curr->is_free && curr->size >= size) {
            // Split: 大块切分, 后半段重新标记为空闲
            if(curr->size >= size + sizeof(struct kmem_header) + 8) {
                struct kmem_header *new_block = (struct kmem_header*)
                    ((char*)curr + sizeof(struct kmem_header) + size);
                new_block->size = curr->size - size - sizeof(struct kmem_header);
                new_block->is_free = 1;
                new_block->next = curr->next;
                curr->size = size;
                curr->next = new_block;
            }
            curr->is_free = 0;
            release(&kmalloc_mem.lock);
            return (void*)(curr + 1); // 返回数据区地址 (跳过 header)
        }
        curr = curr->next;
    }
    release(&kmalloc_mem.lock);
    // 申请新 4KB 页挂入链表并重试
    void *page = kalloc();
    if(page == 0) return 0;
    // ... 页块挂载与重新尝试路径 ...
}

void kmfree(void *addr) {
    // ... 标记 is_free=1 ...
    // Coalesce: 合并物理上连续的相邻空闲块
    struct kmem_header *curr = kmalloc_mem.head;
    while(curr) {
        if(curr->is_free && curr->next && curr->next->is_free) {
            if((char*)curr + sizeof(struct kmem_header) + curr->size
                == (char*)curr->next) {
                curr->size += sizeof(struct kmem_header) + curr->next->size;
                curr->next = curr->next->next; // 合并空闲块
                continue; // 重新检查
            }
        }
    }
}
```

```

    }
    curr = curr->next;
}
}

```

B. 按需分页 (Lazy Allocation)

1. 算法控制流：惰性分配与缺页补全

- **申请时 (sys_sbrk)**：仅调整进程虚拟地址空间上界 $p \rightarrow sz$ ($p \rightarrow sz += n$)，不调用 `kalloc` 申请物理页。
- **缺页触发 (usertrap)**：当进程实际读写未分配的虚拟地址时，触发缺页异常 (`scause == 13/15`)。在 `usertrap()` 中通过 `walk(pagetable, va, 0)` 确认该虚拟地址合法 (属于 $[0, p \rightarrow sz)$ 且未映射)。
- **物理页装载**：调用 `kalloc()` 分配物理物理页，并通过 `mappages()` 补齐页表项映射。
- **透明访问**：重构 `walkaddr()` 与 `copyout()`，使内核在处理系统调用 (如 `read` 写入 Lazy 区域) 时，也能透明且安全地触发物理页装载。
- 同时，修改 `uvmunmap` 与 `uvmcopy`，在检测到未映射页 (`PTE_V == 0`) 时选择跳过，不触发 `panic`。

2. 核心代码 (`kernel/sysproc.c` & `kernel/trap.c`):

```

// sys_sbrk : 增长时仅抬高虚拟边界，不分配物理页
uint64 sys_sbrk(void) {
    uint64 addr;
    int n;
    struct proc *p = myproc();

    argint(0, &n);
    addr = p->sz;

    if(n < 0) {
        if(-n > p->sz)
            return -1;
        // 内存缩减：必须立即调用 growproc 释放物理页
        if(growproc(n) < 0)
            return -1;
    } else {
        // 延迟分配：只向上增长虚拟边界 sz，不分配物理页
        if(p->sz + n >= MAXVA || p->sz + n < p->sz)
            return -1;
        p->sz += n;
    }
    return addr;
}

// usertrap 中：缺页异常动态装载
if(scause == 13 || scause == 15) {
    uint64 va = PGROUNDOWN(r_stval());
    if(r_stval() < PGROUNDUP(p->sz)) {                // 合法性校验 (含页内偏移)
        char *mem = kalloc();                          // 分配物理页
        if(mem == 0) { setkilled(p); }
        else {
            memset(mem, 0, PGSIZE);
        }
    }
}

```



```

        if(mappages(p->pagetable, va, PGSIZE, (uint64)mem, PTE_R|PTE_W|PTE_U) <
0) {
            kfree(mem);
            setkilled(p);
        }
    } else {
        setkilled(p); // 非法越界地址，结束进程
    }
}

```

C. 写时复制 (Copy-On-Write Fork)

1. 核心数据结构：物理页引用计数池 (kernel/kalloc.c):

```

// 全局物理页引用计数池
struct {
    struct spinlock lock; // 并发保护自旋锁
    char counts[PHYSTOP / PGSIZE]; // 物理页引用计数数组
} page_ref;

void ref_inc(uint64 pa) {
    if(pa < (uint64)end || pa >= PHYSTOP)
        return;
    acquire(&page_ref.lock);
    page_ref.counts[pa / PGSIZE]++;
    release(&page_ref.lock);
}

void ref_dec(uint64 pa) {
    if(pa < (uint64)end || pa >= PHYSTOP)
        return;
    acquire(&page_ref.lock);
    page_ref.counts[pa / PGSIZE]--;
    release(&page_ref.lock);
}

int ref_get(uint64 pa) {
    if(pa < (uint64)end || pa >= PHYSTOP)
        return 0;
    int c;
    acquire(&page_ref.lock);
    c = page_ref.counts[pa / PGSIZE];
    release(&page_ref.lock);
    return c;
}

```

2. 自定义页表标志位 (kernel/riscv.h):

```

#define PTE_COW (1L << 8) // 写时复制标记：利用 RISC-V PTE 保留位[8]标识 COW 页

```

3. 算法控制流：COW Fork 两阶段控制流

- **阶段一：Fork 时 (uvmcopy)：共享页表** 遍历父进程页表。对可写 (PTE_W) 页面，清除写权限，打上 PTE_COW 标记。然后调用 ref_inc(pa) 递增引用计数，并使子进程页表指向同一物理页，实现零拷贝共享。
- **阶段二：写入时 (cow_alloc)：物理页分裂** 进程尝试写入打上 PTE_COW 的页面时，硬件触发 scause == 15。内核通过 cow_alloc() 拦截并处理：
 - 若引用计数 == 1 (独占状态)：直接清除 PTE_COW 恢复写权限 (PTE_W)，原地分裂。
 - 若引用计数 > 1 (共享状态)：分配新物理页，进行数据拷贝，将新页重新映射到当前虚拟地址并赋予 PTE_W 权限，同时原页引用计数递减。
 - 刷新 TLB (sfence_vma())。
- **kfree 物理页延迟回收**：重构 kfree，仅在引用计数归零时，才将物理页真正归还到空闲链表。

4. 核心代码 (kernel/vm.c):

```
// Fork 时：共享映射 + 打 COW 标记 (零拷贝)
int uvmcopy(pagetable_t old, pagetable_t new, uint64 sz) {
    pte_t *pte;
    uint64 pa, i;
    uint flags;

    for(i = 0; i < sz; i += PGSIZE){
        if((pte = walk(old, i, 0)) == 0)
            continue;
        if((*pte & PTE_V) == 0)
            continue;
        pa = PTE2PA(*pte);
        flags = PTE_FLAGS(*pte);

        if(flags & PTE_W) {
            flags = (flags & ~PTE_W) | PTE_COW;           // 清写权限 + 打 COW 标记
            *pte = (*pte & ~PTE_W) | PTE_COW;
        }
        ref_inc(pa);                                       // 递增物理页引用计数
        if(mappages(new, i, PGSIZE, pa, flags) != 0){    // 映射失败回退引用计数
            ref_dec(pa);
            goto err;
        }
    }
    return 0;

err:
    uvmunmap(new, 0, i / PGSIZE, 1);
    return -1;
}

// 缺页时：COW 物理页分裂
int cow_alloc(pagetable_t pagetable, uint64 va) {
    if(va >= MAXVA) return -1;
    uint64 va0 = PGROUNDDOWN(va);
    pte_t *pte = walk(pagetable, va0, 0);
    if(pte == 0 || (*pte & PTE_V) == 0) return -1;

    if(*pte & PTE_COW) {
```

```

uint64 pa = PTE2PA(*pte);
uint flags = PTE_FLAGS(*pte);

if(ref_get(pa) == 1) {
    // 独占引用：原地恢复写权限
    *pte = (*pte & ~PTE_COW) | PTE_W;
} else {
    // 共享引用：分配新物理页并执行数据拷贝
    char *mem = kalloc();
    if(mem == 0) return -1;
    memmove(mem, (char*)pa, PGSIZE);
    *pte = PA2PTE(mem) | ((flags & ~PTE_COW) | PTE_W);
    kfree((void*)pa); // 递减原物理页引用计数
}
sfence_vma(); // 刷新本核 TLB
}
return 0;
}

```

D. mmap/munmap 文件内存映射

为了避免传统 read/write 系统调用带来的内核态与用户态双重数据拷贝，本项目实现了基于 VMA（虚拟内存区域）的文件内存映射机制。

1. 核心数据结构（kernel/proc.h 中的 VMA 结构体定义）：

```

// 虚拟内存区域结构（每个进程支持最大 16 个 VMA 槽位）
struct vma {
    int valid; // 槽位是否被占用
    uint64 addr; // 映射起始虚拟地址（4KB 对齐）
    int len; // 映射长度（字节）
    int prot; // 访问权限（PROT_READ / PROT_WRITE）
    int flags; // MAP_SHARED（共享回写）或 MAP_PRIVATE（私有写时复制）
    struct file *f; // 关联的文件结构体指针
    int offset; // 映射在文件内部的偏移量
};

```

2. 算法控制流：虚拟登记与延迟装载

- **映射建立（sys_mmap）**：调用 sys_mmap() 时，不立即分配物理页，亦不读取磁盘。仅在 PCB 中查找一个空闲的 struct vma 槽位，登记其起止地址、偏移、文件及标志属性，并递增文件引用。
- **缺页读入（usertrap/mmap_alloc）**：当进程实际读取该 VMA 地址区间发生缺页（scause == 13/15）时，内核捕获此异常，并在 usertrap() 中分配一个 4KB 物理页，根据 vma 记录的文件与偏移信息，通过调用 readi 读盘并填充物理页，最后将其映射至用户态虚拟地址。
- **回写与卸载（sys_munmap）**：进程主动调用 sys_munmap 或执行 exit() 销毁虚拟内存空间时：
 - 系统遍历该 VMA 中所有已映射页。
 - 若映射标志为 MAP_SHARED 且该物理页被修改过（PTE 的 PTE_D 被硬件标记为脏页，或判定为可写），则调用 writei 将修改内容回刷至磁盘对应文件中。
 - 通过 uvmunmap 解除页表映射，释放物理内存并递减文件指针引用。

3. 核心代码 (kernel/sysfile.c & kernel/trap.c):

```
// mmap 系统调用：建立 VMA 区域，延迟物理装载
uint64 sys_mmap(void) {
    uint64 addr;
    int len, prot, flags, fd, offset;
    struct file *f;
    struct proc *p = myproc();

    argaddr(0, &addr);
    argint(1, &len);
    argint(2, &prot);
    argint(3, &flags);
    argint(4, &fd);
    argint(5, &offset);

    if(argfd(4, 0, &f) < 0)
        return -1;

    // 权限防御：共享可写映射要求文件本身可写
    if((prot & PROT_WRITE) && (flags & MAP_SHARED) && (f->writable == 0))
        return -1;

    if(f->type != FD_INODE)
        return -1;

    // 寻找空闲的 VMA 槽位
    struct vma *v = 0;
    for(int i = 0; i < 16; i++) {
        if(p->vmass[i].valid == 0) { v = &p->vmass[i]; break; }
    }
    if(v == 0) return -1;

    // 自动寻找未被占用的高虚拟地址区间（1GB 以上起始）
    uint64 va = 0x40000000;
    for(int i = 0; i < 16; i++) {
        if(p->vmass[i].valid && p->vmass[i].addr + p->vmass[i].len > va) {
            va = PGROUNDUP(p->vmass[i].addr + p->vmass[i].len);
        }
    }

    v->valid = 1;
    v->addr = va;
    v->len = len;
    v->prot = prot;
    v->flags = flags;
    v->f = filedup(f);    // 递增文件引用计数
    v->offset = offset;

    return va;
}

// usertrap() 中对 VMA 页面的缺页懒加载（内联逻辑）
```

```
// 1. 先检查缺页地址是否属于某个 VMA 映射区
struct vma *v = 0;
for(int i = 0; i < 16; i++) {
    if(p->vmas[i].valid && stval >= p->vmas[i].addr
        && stval < p->vmas[i].addr + p->vmas[i].len) {
        v = &p->vmas[i]; break;
    }
}
if(v != 0) {
    // 写异常 + 只读映射 → 拒绝
    if(scause == 15 && !(v->prot & PROT_WRITE)) { setkilled(p); }
    else {
        char *mem = kalloc();
        memset(mem, 0, PGSIZE);
        ilock(v->f->ip);
        int file_offset = v->offset + (va0 - v->addr);
        readi(v->f->ip, 0, (uint64)mem, file_offset, PGSIZE);
        iunlock(v->f->ip);
        int perm = PTE_U;
        if(v->prot & PROT_READ) perm |= PTE_R;
        if(v->prot & PROT_WRITE) perm |= PTE_W;
        mappages(p->pagetable, va0, PGSIZE, (uint64)mem, perm);
    }
}
```

3.3.4 进程管理 (Process Management)

A. FCFS + RR 调度器

1. 核心数据结构 (kernel/proc.h):

```
struct proc {
    // ...
    uint ctime;           // 进程创建时间戳：用于 FCFS 调度选取最早进程
    enum procstate state; // 进程状态：UNUSED, USED, SLEEPING, RUNNABLE,
    RUNNING, ZOMBIE
    // ...
};

// 全局调度模式变量 (0: Round-Robin, 1: FCFS 先来先服务)
int sched_mode;
```

2. 算法控制流：调度切换控制 调度器主循环 `scheduler()` 在空闲核心上运行。每次遍历进程表时，通过 `sched_mode` 确定调度策略：

- **RR 模式 (0)**：每次时钟中断触发时执行 `yield()`，当前进程让出 CPU 并标记为 `RUNNABLE`，CPU 重新轮转扫描首个可运行进程。
- **FCFS 模式 (1)**：遍历进程表，在所有 `RUNNABLE` 的就绪进程中选取创建时间戳 `ctime` 最小（即最早到达）的一个投入运行。时钟中断下不抢占进程，当前进程持续运行至主动 `exit()` 或发生 IO 阻塞 (`sleep()`) 调用 `sched()` 让出 CPU。

3. 核心代码 (kernel/proc.c):

```

void scheduler(void) {
    struct proc *p;
    struct cpu *c = mycpu();
    c->proc = 0;
    for(;;){
        intr_on();
        if(sched_mode == 0) {
            // RR 调度 (持锁-检查-释放, 逐进程处理)
            for(p = proc; p < &proc[NPROC]; p++) {
                acquire(&p->lock);
                if(p->state == RUNNABLE) {
                    p->state = RUNNING;
                    c->proc = p;
                    swtch(&c->context, &p->context);
                    c->proc = 0;
                }
                release(&p->lock);
            }
        } else {
            // FCFS 调度: 两遍扫描
            struct proc *first_p = 0;
            int first_ctime = 0;
            // 第一遍: 逐进程持锁-检查-释放, 找到 ctime 最小的 RUNNABLE 进程
            for(p = proc; p < &proc[NPROC]; p++) {
                acquire(&p->lock);
                if(p->state == RUNNABLE) {
                    if(first_p == 0 || p->ctime < first_ctime) {
                        first_ctime = p->ctime;
                        first_p = p;
                    }
                }
                release(&p->lock);
            }
            // 第二遍: 锁定选中的进程, 验证状态后投入运行
            if(first_p) {
                acquire(&first_p->lock);
                if(first_p->state == RUNNABLE) {
                    first_p->state = RUNNING;
                    c->proc = first_p;
                    swtch(&c->context, &first_p->context);
                    c->proc = 0;
                }
                release(&first_p->lock);
            }
        }
    }
}

```

B. waitpid 机制

1. 算法控制流：精准子进程回收与非阻塞 在原有 `wait` 机制上扩展：

- **精准回收**：若参数 `target_pid > 0`，则扫描子进程表时仅匹配 PID 对应的特定子进程；若 `target_pid == -1`，回退为回收任意子进程。
- **非阻塞 (WNOHANG)**：若指定 WNOHANG 且匹配的目标子进程非 ZOMBIE 状态，函数不挂起父进程，而是**立即返回 0**，允许父进程继续执行。

2. 核心代码 (`kernel/proc.c`):

```
int waitpid(int target_pid, uint64 addr, int options) {
    struct proc *pp;
    int havekids, pid;
    struct proc *p = myproc();

    acquire(&wait_lock);
    for(;;){
        havekids = 0;
        for(pp = proc; pp < &proc[NPROC]; pp++){
            if(pp->parent == p){
                if(target_pid > 0 && pp->pid != target_pid) continue; // 匹配目标 PID
                acquire(&pp->lock);
                havekids = 1;
                if(pp->state == ZOMBIE){
                    pid = pp->pid;
                    int temp_xstate = pp->xstate;
                    freeproc(pp); // 彻底回收资源
                    release(&pp->lock);
                    release(&wait_lock);
                    // 状态写回用户态
                    if(addr != 0 && copyout(p->pagetable, addr, (char *)&temp_xstate,
                                           sizeof(temp_xstate)) < 0) {
                        return -1;
                    }
                    return pid;
                }
                release(&pp->lock);
            }
        }
        if(!havekids || killed(p)){ release(&wait_lock); return -1; }
        if(options == 1){ release(&wait_lock); return 0; } // WNOHANG
        sleep(p, &wait_lock); // 阻塞挂起等待
    }
}
```

C. 信号量 (Semaphore)

1. 核心数据结构 (`kernel/sem.c`):

```
struct sem {
    struct spinlock lock; // 保护计数的自旋锁
```

```
int count;           // 可用资源数
};
```

2. 算法控制流：基于 sleep/wakeup 的进程级锁机制 利用内核字节级堆分配器 kmalloc 动态创建及回收 sem。在 sem_wait 中，先递减计数；若计数变为负数（资源耗尽），调用内核 sleep 挂起进程。P/V 操作均直接使用信号量内存地址作为睡眠通道（chan），从而在 sem_signal 中通过 wakeup(s) 实现精准调度。

3. 核心代码（kernel/sem.c）：

```
int sem_wait(uint64 sem_addr) {           // P 操作：申请资源
    struct sem *s = (struct sem*)sem_addr;
    acquire(&s->lock);
    s->count--;
    while(s->count < 0) {
        sleep(s, &s->lock);               // 资源不足，挂起在信号量 s 上
    }
    release(&s->lock);
    return 0;
}

int sem_signal(uint64 sem_addr) {          // V 操作：释放资源并唤醒
    struct sem *s = (struct sem*)sem_addr;
    acquire(&s->lock);
    s->count++;
    if(s->count <= 0) {
        wakeup(s);                       // 有进程在等待时，唤醒在通道 s 上的进程
    }
    release(&s->lock);
    return 0;
}
```

D. Alarm 异步定时器

1. 核心数据结构：struct proc 成员（kernel/proc.h）：

```
struct proc {
    // ...
    int alarm_interval;           // 触发间隔
    uint64 alarm_handler;         // 用户态处理函数地址
    int alarm_ticks;              // 滴答累计计数
    struct trapframe *alarm_tf;   // 动态备份现场（kmalloc 分配）
    int alarm_running;            // 标志位：防处理函数重入触发
};
```

2. 算法控制流：中断重定向与恢复 当时钟中断触发且 alarm_ticks 达到上限时，内核动态分配（kmalloc）一块 struct trapframe 保存当前所有通用寄存器与程序计数器（epc），重置 alarm_ticks。随后将 p->trapframe->epc 强行覆盖为处理函数 alarm_handler 并在进程返回时跳转执行。当处理函数完成后，用户态显式执行 sigreturn 系统调用，将备份现场完整复制回当前内核 trapframe，并重置 alarm_running。

3. 核心代码 (kernel/trap.c/kernel/sysproc.c):

```
// usertrap() 中:时钟中断触发 alarm 信号
if(which_dev == 2 && p->alarm_interval > 0 && p->alarm_running == 0) {
    p->alarm_ticks++;
    if(p->alarm_ticks == p->alarm_interval) {
        p->alarm_ticks = 0;
        p->alarm_running = 1;           // 先置防重入锁,防止嵌套触发
        *p->alarm_tf = *p->trapframe;   // 备份完整寄存器现场
        p->trapframe->epc = p->alarm_handler; // 重定向返回地址到用户 handler
    }
}

// sigreturn 系统调用:恢复现场并清除防重入锁
uint64 sys_sigreturn(void) {
    *p->trapframe = *p->alarm_tf;      // 恢复寄存器原现场
    p->alarm_running = 0;               // 解除重入保护
    return p->trapframe->a0;             // 保护返回值(避免被 syscall 框架覆盖)
}
```

3.3.5 文件系统 (File System)

A. lseek 文件定位

1. 核心数据结构 (kernel/file.h):

```
struct file {
    int off;           // 当前文件读写偏移量(字节)
    struct inode *ip;  // 指向文件 Inode
    // ...
};
```

2. 算法控制流:多核保护与随机访问

- 支持 SEEK_SET (开头)、SEEK_CUR (当前)、SEEK_END (末尾) 模式。
- 操作前调用 ilock(f->ip) 获取 Inode 级睡眠锁,保障在多进程/多核竞争下更新偏移量和文件大小一致。过滤非法 fd 与非磁盘文件定位。

3. 核心代码 (kernel/sysfile.c):

```
uint64 sys_lseek(void) {
    struct file *f;
    int offset;
    int whence;

    argint(1, &offset);
    argint(2, &whence);
    if(argfd(0, 0, &f) < 0)
        return -1;
}
```

```

if(f->type != FD_INODE)                // 仅支持普通 inode 文件
    return -1;

struct inode *ip = f->ip;
int new_off = f->off;

ilock(ip);                            // Inode 锁保护
if(whence == 0)    new_off = offset;
else if(whence == 1) new_off = f->off + offset;
else if(whence == 2) new_off = ip->size + offset;
else { iunlock(ip); return -1; }

if(new_off < 0) { iunlock(ip); return -1; }
f->off = new_off;
iunlock(ip);
return new_off;
}

```

B. Symlink 软链接

1. 核心数据结构 (`kernel/stat.h` / `kernel/fcntl.h`):

```

#define T_SYMLINK 4            // 软链接类型
#define O_NOFOLLOW 0x004     // 打开时不跟随软链接

```

2. 算法控制流：环路检测与递归跟随

- 创建：分配 T_SYMLINK 类型的 inode，并通过 writei 将指向的目标路径写入其数据块中。
- 解析：在 sys_open() 路径中，若打开的是软链接且无 O_NOFOLLOW 标志，则通过 readi 读出目标路径，调用 namei 递归查找。限制递归解析最大层级为 10，超过判定为环路死循环并返回失败。

3. 核心代码 (`kernel/sysfile.c`):

```

// 创建软链接
uint64 sys_symlink(void) {
    begin_op();
    ip = create(path, T_SYMLINK, 0, 0);
    if(ip == 0) { end_op(); return -1; }
    // 将目标路径写入该 Inode 的数据块中
    if(writei(ip, 0, (uint64)target, 0, strlen(target)) != strlen(target)) {
        iunlockput(ip);
        end_op();
        return -1;
    }
    iupdate(ip);
    iunlockput(ip);
    end_op();
    return 0;
}

```

```

// sys_open() 递归解析逻辑
int depth = 0;
while(ip->type == T_SYMLINK && !(omode & O_NOFOLLOW)) {
    if(depth >= 10) { // 超过 10 层说明存在环路，中断
        报错
        iunlockput(ip);
        end_op();
        return -1;
    }
    depth++;
    char target_path[MAXPATH];
    memset(target_path, 0, MAXPATH);
    if(readi(ip, 0, (uint64)target_path, 0, ip->size) != ip->size) {
        iunlockput(ip);
        end_op();
        return -1;
    }
    iunlockput(ip);
    if((ip = namei(target_path)) == 0) { // 递归寻路
        end_op();
        return -1; // 断头链接，打开失败
    }
    ilock(ip);
}

```

3.3.6 多线程机制 (Clone)

1. 核心数据结构：线程管理字段 (kernel/proc.h):

```

struct proc {
    // ...
    pagetable_t pagetable; // 独立顶级页表
    int is_thread; // 线程标志位
    int tgid; // 线程组 ID (tgid == 主线程的 pid)
    // ...
};

```

2. 算法控制流：物理页共享多线程 (LWP) 模型

- **共享与隔离**：为子线程分配独立的 PCB 及专属的 trapframe 物理页，在 CPU 调度上下文切换时隔离核心寄存器。
- **物理共享**：自定义 uvmssharecopy，将父进程的用户态虚拟页表项原样（不加 PTE_COW）复制到子线程的独立页表中，共享相同的物理内存，并对映射的物理页调用 ref_inc。
- **状态拷贝**：子线程拥有独立用户态栈 stack，并在 trapframe 中通过 a0 传递参数。父子线程在终结时独立递减物理页计数，当线程组最后一个活跃成员退出时，真正释放共享的虚拟空间物理页。

3. 核心代码 (kernel/proc.c):

```
int clone(uint64 fn, uint64 stack, uint64 arg) {
    int i, pid;
    struct proc *np;
    struct proc *p = myproc();

    // 1. 分配独立 PCB 与独立顶级页表
    if((np = allocproc()) == 0) return -1;

    // 2. 映射同一套用户虚拟物理页
    if(uvmsharecopy(p->pagetable, np->pagetable, p->sz) < 0){
        freeproc(np);
        release(&np->lock);
        return -1;
    }
    np->sz = p->sz;

    *(np->trapframe) = *(p->trapframe);
    np->trapframe->epc = fn;                // 入口函数
    np->trapframe->sp = stack;              // 独立用户栈
    np->trapframe->a0 = arg;                // 传参

    // 3. 共享文件表与 VMA
    for(i = 0; i < NOFILE; i++)
        if(p->ofile[i]) np->ofile[i] = filedup(p->ofile[i]);
    np->cwd = idup(p->cwd);
    for(i = 0; i < 16; i++)
        if(p->vmass[i].valid) { np->vmass[i] = p->vmass[i]; filedup(p->vmass[i].f); }

    safestrcpy(np->name, p->name, sizeof(p->name));
    pid = np->pid;


    np->is_thread = 1;
    np->tgid = p->tgid;                    // 绑定线程组

    release(&np->lock);

    // 挂载父子关系, 便于 wait()/waitpid() 正常回收
    acquire(&wait_lock);
    np->parent = p;
    release(&wait_lock);

    acquire(&np->lock);
    np->state = RUNNABLE;
    release(&np->lock);

    return pid;
}
```



3.3.7 Futex 用户态快速同步锁

1. 核心数据结构 (kernel/proc.c):

```
#define FUTEX_WAIT 0
#define FUTEX_WAKE 1

struct spinlock futex_lock; // 全局锁保护挂起原子性
```

2. 算法控制流: "原子检查-挂起"防御 Lost-Wakeup 唤醒竞争

- **Lost-Wakeup 隐患消除:** 在 `sys_futex(uaddr, FUTEX_WAIT, val)` 中, 获取全局自旋锁 `futex_lock` 后, 使用 `copyin` 从用户态再次检查实际值是否仍为 `val`。若当前值已变为非期望值 (说明其他线程已快速释放锁), 直接释放锁并退出 (返回 -2 通知用户态自旋重试), 消除挂起与检查之间的竞态窗口。
- **通道标识与线程组隔离:** 将用户虚拟地址映射通过页表 `walk` 提取出唯一物理地址 (`paddr`) 作为睡眠通道, 避免在同一物理页内跨进程的地址发生冲突, 遍历进程表唤醒时, 限定同 `tgid` 以实现线程组的范围隔离。

3. 核心代码 (kernel/proc.c):

```
uint64 sys_futex(void) {
    uint64 uaddr; int op, val;
    argaddr(0, &uaddr); argint(1, &op); argint(2, &val);

    // 地址对齐检验
    if(uaddr % 4 != 0)
        return -1;

    // 虚拟地址 → 物理地址 (作为同步 Key, 含页内偏移量确保唯一性)
    uint64 paddr = walkaddr(p->pagetable, uaddr);
    if(paddr == 0) return -1;
    paddr = paddr + (uaddr % PGSIZE);

    if(op == FUTEX_WAIT) {
        acquire(&futex_lock);
        int cur_val;
```


```

if(copyin(p->pagetable, (char*)&cur_val, uaddr, sizeof(int)) < 0) {
    release(&futex_lock);
    return -1;
}
if(cur_val != val) {
    release(&futex_lock);                // 原子检查：锁已被释放，退回用户态自旋
    return -2;                          // 返回 EAGAIN
}
acquire(&p->lock);
p->chan = (void*)paddr;                // 物理地址作同步睡眠通道
p->state = SLEEPING;
release(&futex_lock);
sched();                              // 进程切换挂起
p->chan = 0;
release(&p->lock);
return 0;
} else if(op == FUTEX_WAKE) {
    acquire(&futex_lock);
    int woken = 0;
    // 唤醒同 tgid 且处于同一同步物理通道的等待进程
    for(struct proc *np = proc; np < &proc[NPROC]; np++) {
        if(np != p) {
            acquire(&np->lock);
            if(np->state == SLEEPING && np->chan == (void*)paddr
                && np->tgid == p->tgid) {
                np->state = RUNNABLE;
                woken++;
            }
            release(&np->lock);
            if(woken >= val) break;
        }
    }
    release(&futex_lock);
    return woken;                      // 返回实际唤醒数量
}
return -1;
}

```

四、测试与验证

为了验证系统在功能性、稳定性和高负载下的实际表现，本项目构建了一个三维测试与验证体系：



4.1 测试方案

- **功能测试**：针对新增功能分别自行设计测试程序或引入官方测试文件，精准验证**单一模块功能的正确性**。
- **异常测试**：构造非法内存访问和异常系统调用场景，验证**系统异常隔离能力和资源回收能力**。
- **系统测试**：运行 **xv6 原生测试集 usertests**，全面验证进程管理、内存管理、文件系统及系统调用等核心功能的正确性与兼容性。
- **集成测试**：实现**统一测试框架 alltests.c**，对**新增功能测试、异常测试以及 xv6 原生 usertests** 共 21 项进行统一调度，实现**一键式自动化测试**。通过集成运行验证各模块之间的兼容性与协同工作能力，并检查系统整体稳定性。
- **压力测试**：运行 xv6 原生的 **grind** 测试，测试系统稳定性。

具体：[测试说明文档 \(devlog/test.md\)](#)

4.2 alltests 集成测试内容

本项目设计了 alltests 集成测试框架，用于统一调度与运行增量的功能测试。测试项涵盖以下几个方面：


- **功能测试**：crash_test.c、ps.c、kmalloctest.c、sched.c、schedtest.c、waitpidtest.c、semtest.c、alarmtest.c、symlinktest.c、lazytasks.c、cowtest.c、mmaptest.c、clonetest.c、futetest.c。
- **xv6 官方综合测试集 usertests.c**，覆盖：
 - 系统调用参数合法性：非法用户指针、越界地址、超长字符串
 - 进程与内存管理：fork、wait、exit、kill、sbrk
 - 文件系统功能：文件创建、删除、读写、链接、目录操作
 - 并发与压力：大量并发 fork、文件操作竞争
 - 异常与鲁棒性：非法内存访问、资源耗尽

4.3 grind 压力测试

- **grind.c**：xv6 官方压力测试，创建两个子进程，高强度随机执行 23 种操作（fork、kill、文件读写、sbrk、管道等），在持续运行过程中未出现 panic、死锁或异常退出。字符交替输出（如 **ABBABA**）表明多核同步锁设计正确。

4.4 测试结果

运行 **alltests** 全量通过 (**PASS: 21/21**)；grind 连续运行数十分钟，系统稳定。



五、LLM 推理引擎移植与性能验证

随着生成式人工智能的高速发展，大语言模型（LLM）的推理任务正逐步从云端向边缘侧与嵌入式设备迁移。在计算资源有限的软硬件环境下，**提高 AI 推理程序的运行速度并降低其资源开销**，不仅依赖于算法层面的量化与剪枝，也取决于底层操作系统能否提供高效的**多核调度、快速的线程同步以及零拷贝的存储访问**。

原生的 **xv6-riscv** 作为一个教学操作系统，其设计初衷在于**展示 Unix 的核心概念**，因而在应对算力密集型与 I/O 密集型并存的真实 AI 负载时，存在**并发能力弱、同步开销大以及 I/O 效率较低**的局限。

基于上述背景，本项目在 alltests 测试全部通过、grind 长时间运行系统稳定的前提下，将极简 Transformer 推理引擎 **llama2.c**（由 Andrej Karpathy 开源）移植至 xv6-riscv，命名为 llama.c。本章通过在系统内加载运行 stories260K.bin 模型（1.04MB），设计多组系统级对比实验。其核心目的在于：以大模型推理为真实重载应用闭环，**量化评估**本项目增量实现的轻量级线程（Clone）、快速同步（Futex）和存储映射（mmap）等优化机制，**相较于 xv6 传统基线机制所取得的性能改善幅度**。

- 实验程序 llama.c 移植自 [karpathy/llama2.c](#)，模型使用 [stories260K.bin](#)（约 1.04MB），分词器使用 tok512.bin。

5.1 llama.c 移植

llama.c 是一个极简的 Transformer 推理程序。它加载预训练的模型权重，并根据提示词逐个生成后续的 Token。原版的 run.c 依赖标准的数学库（<math.h>）、OpenMP 多线程库以及标准文件 I/O（fopen/fread）。由于 xv6 缺乏完整的 C 标准库支持，本项目对其进行了如下适配移植：

- 数值逼近手写数学函数**：由于 xv6 用户态不支持 <math.h>，而 Transformer 推理中的 RoPE 旋转位置编码和 Softmax 归一化需要大量的指数与三角函数计算，本项目采用数值逼近方法（如泰勒级数展开及快

速平方根算法) 手写实现了 exp、sqrt、sin、cos 等函数。

- **轻量级静态线程池**：通过扩展的 clone 系统调用构建静态工作线程池，替代原版依赖的 OpenMP 实现。多线程主要用于并行加速**矩阵-向量乘法 (matmul) 算子**，该算子占用了推理过程中 90% 以上的计算时间。为了对比不同的同步开销，我们在线程池中实现了三种同步驱动方式：
 - **Spinlock 模式**：线程在用户态通过原子变量进行忙等待，不发生内核转换，但空转消耗 CPU。
 - **Pipe 模式**：通过内核管道的 read/write 实现线程的阻塞与唤醒，每次同步都必须经历系统调用。
 - **Futex 模式**：利用本项目实现的 sys_futex，在无竞争时在用户态快速返回，有竞争时通过内核挂起与精准唤醒。
- **重构文件读取路径**：用 open/read/stat/close 替换标准的 fopen/fread 等流操作。模型加载支持以下两种方式对比：
 - **mmap 映射模式**：直接利用 sys_mmap 将模型权重文件映射到虚拟地址空间，实现零拷贝按需加载。
 - **malloc + read 模式**：先通过 sbrk 申请内存空间，再通过标准文件系统接口将权重数据复制到用户缓冲区。

5.2 实验一：多核可扩展性实验

- **实验目的**：验证多线程并行计算能否有效加速推理。把 matmul() 中的矩阵行切分到多个核心上并发执行，观察随着线程数增加，生成 Token 的速度能提升多少。
- **实验设计**：
 - QEMU 配置物理 4 核心 (-smp 4)，并发工作线程数分别设置为 1、2、4。
 - 使用 Futex 作为基础同步机制，在 RR（轮转）与 FCFS（先来先服务）两种调度策略下分别测试 3 轮，每轮推理生成 10 个 Token，记录消耗的系统 Ticks（时钟中断次数）并求取均值。
 - 由于所采用的 stories260K 模型隐藏层维度仅为 64，单次矩阵运算的物理耗时远小于 sys_futex 的内核陷入与上下文切换开销，导致无法显现并行优势。本实验在 matmul 算子最内层循环中引入**计算密度放大因子**（FACTOR = 100），通过增大单次任务的算术强度，评估该系统的性能。

• 实验数据

调度模式	线程数	轮 1	轮 2	轮 3	平均 Ticks	加速比
RR	1	36	39	35	36.7	1.00×
	2	23	25	24	24.0	1.53×
	4	20	20	20	20.0	1.84×
FCFS	1	35	35	36	35.3	1.00×
	2	24	25	25	24.7	1.43×
	4	21	22	22	21.7	1.63×

• 数据分析

- **并行提升**：在两种调度模式下，从 1 线程增加到 2 线程，性能均获得了明显的提升（RR 下为 1.53×，FCFS 下为 1.43×），表明矩阵乘法运算的行切分负载能够较好地利用物理核心。

- **边际效益递减**：从 2 线程增加到 4 线程时，加速比曲线趋缓（4 线程下 RR 为 1.84×，FCFS 为 1.63×）。这符合 Amdahl 定律，因为除矩阵乘法外的串行过程（RoPE 编码、多头注意力非并行部分）以及多核之间并发竞争系统调度器锁、物理内存分配锁等内核同步开销，限制了加速比的线性延伸。
- **调度器对比**：在多线程协作频繁睡眠唤醒的情况下，RR（时间片轮转）由于具备对就绪线程的及时抢占能力，使 worker 线程在状态就绪时能更快地获得 CPU 分配，因此其实际表现略好于非抢占式的 FCFS。

5.3 实验二：同步机制对比实验

- **实验目的**：多线程并行计算时，工作线程之间、工作线程与主线程之间需要同步。量化对比三种用户态同步方式（空转、内核态管道、Futex 机制）在多线程频繁同步时的效率损耗。
- **实验设计**
 - RR 调度，4 个线程，3 轮重复，每轮生成 10 个 Token。
 - 分别使用 **Spinlock**、**Pipe**、**Futex** 三种同步方式。
 - Spinlock：通过在用户态对原子共享标记变量进行无限忙等待，不执行系统调用。
 - Pipe：工作线程通过 read() 系统调用阻塞在内核管道上，主线程通过 write() 写入同步信号唤醒。
 - Futex：工作线程在状态未就绪时通过 futex_wait 进入内核挂起，主线程完成计算后通过 futex_wake 精准唤醒。

• 实验数据

同步方式	轮 1	轮 2	轮 3	平均 Ticks	相比 Spinlock
Spinlock	270	266	269	268.3	-
Pipe	36	33	32	33.7	快 87.4%
Futex	20	20	21	20.3	快 92.4%

• 数据分析

- **Spinlock 效率瓶颈**：由于物理 CPU 仅有 4 个，但包含主线程在内的计算调度实体达到了 5 个。使用 Spinlock 会导致空闲等待的工作线程死死占用物理核心而不主动让出，造成严重的 CPU 算力空转浪费，导致平均耗时达到 268.3 Ticks。
- **Pipe 挂起让出**：使用 Pipe 机制后，等待的工作线程在调用 read() 后会立刻进入阻塞状态并被移出就绪队列，将物理核心让渡给主线程或其他计算实体，减少无效空转，使运行效率大幅提升了 87.4%。
- **Futex 的核心优势**：Futex 相比 Pipe 在平均时间上进一步缩短了约 40%（从 33.7 Ticks 降至 20.3 Ticks）。这是因为 Futex 贯彻了 Fast-path 设计思想，只有在真正需要睡眠时才陷入内核（Slow-path），在无竞争或信号提前发出时直接在用户态解决，省去了多余的系统调用及上下文切换开销，达到了最优的整体表现。

5.4 实验三：存储映射冷启动对比实验

- **实验目的**：验证并对比大模型权重文件在 malloc + read 传统阻塞载入与 mmap 文件存储映射机制下的冷启动（Cold-start）初始化耗时。

- 实验设计
 - 单线程运行，针对 1.04MB 规模的 stories260K.bin 模型权重文件，分别调用两种不同的读取方式。
 - 用 uptime() 系统调用测量加载前后的 Ticks 差值作为冷启动耗时
- 实验数据

加载方式	I/O 机制	冷启动耗时
malloc + read	用户堆空间申请 + 阻塞式磁盘读取 + 内核/用户态双重拷贝	21 Ticks
mmap	仅页表虚拟 VMA 建立 + 后续读写触发按需缺页调入（零拷贝）	0 Ticks

- 数据分析
 - 在 malloc + read 模式下，系统在执行计算前必须完整经历磁盘读操作、文件缓冲到进程空间的双重拷贝，冷启动耗时达到了 21 Ticks。在此期间，CPU 需阻塞等待磁盘控制器响应。
 - 在 mmap 模式下，冷启动耗时表现为 **0 Ticks**（耗时小于一个时钟滴答）。这得益于其延迟装载设计，mmap 建立映射的过程并不实际触发磁盘读盘，仅修改了页表 VMA 登记项，使冷启动耗时大幅缩短。后续随着推理的展开，仅当数据被读取时才通过缺页异常逐页调入。


5.5 自动化性能验证脚本 `bench.c`

为了便于复现性能评估数据，本项目提供一个自动化脚本 `bench.c`，工作流程：

1. 切换为 RR 调度，运行 Exp1（多核可扩展性），重复 3 轮
2. 切换为 FCFS 调度，再次运行 Exp1，重复 3 轮
3. 切换回 RR 调度，运行 Exp2（同步机制对比），重复 3 轮
4. 运行 Exp3（冷启动对比），1 轮

每个实验通过 `fork()` + `exec()` 调用 llama 程序并传入对应参数（exp1、exp2、exp3），父进程 `wait()` 等待子进程完成后收集结果。调度模式的切换通过 `sched` 程序完成：`sched 0` 切到 RR，`sched 1` 切到 FCFS。

运行 `bench.c` 程序结果如图。



5.6 结论

通过三个实验，本项目对 xv6 系统在以下维度上做了量化评估：

- 多核并行计算能力：**1 → 2 → 4 线程的加速比分别为 1.53× 和 1.84×（RR 模式），证明 xv6 的**多核调度和 clone 线程机制**能有效利用多核心。但受限于串行部分（Amdahl 定律），4 线程未能达到 4× 的线性加速。
- 同步原语的效率差异：**Spinlock 因为 CPU 空转几乎无法用于实际负载（268.3 Ticks）；Pipe 通过内核阻塞大幅改善（33.7 Ticks）；**Futex** 利用 Fast-path/Slow-path 设计在无竞争时避免系统调用，**达到最优（20.3 Ticks）**，比 Pipe 再快 40%。
- 存储映射的零拷贝优势：**mmap 的冷启动延迟为 0 Ticks，对比 malloc + read 的 21 Ticks，在首屏加载速度上有数量级优势。按需调页机制将磁盘 I/O 分散到推理过程中，避免了启动时的阻塞等待。

虽然系统已通过增量功能单元测试与 `usertests` 共 21 项，运行 `grind` 数十分钟无 `panic`、无内存泄漏等异常现象，但在运行测试程序以及 `bench` 时，实验一与二仍有概率发生卡死现象，初步分析可能是 `llama.c` 的线程池销毁阶段存在问题，或者多线程之间竞争导致死锁，或其他原因，还需要进一步分析修复。

六、创新点

1. 完整的内存管理层次

本系统的内存子系统在 Sv39 页表及物理页框分配器的基础上，自下而上构建了**结构完整、层次分明**的虚拟内存体系：物理页分配器（`kalloc`）→ 内核堆分配器（`kmalloc`）→ 虚拟内存（Sv39 页表）→ 按需分页（Lazy）→ 写时复制（COW）→ 文件内存映射（`mmap`）。

2. 轻量级线程与用户态快速同步

基于独立顶级页表 + 物理共享实现 clone 线程 (LWP)，配合 futex 用户态快速锁 (Fastpath 用户态原子操作、Slowpath 内核挂起) 为并发编程提供了完整的基础设施。在 llama2.c 推理程序中验证了多线程并行+高效同步的实际效果。

3. 多维度测试验证与应用闭环

系统的稳定性在“功能 (alltests 包含 usertests) - 压力 (grind) - 真实重载性能 (bench)”三个层面得到验证。将 LLM 推理引擎作为系统的真实负载，在逻辑上闭环验证了各系统调用在边缘状态下的健壮度，同时为操作系统的优化方向提供了可量化的客观参考。

七、总结与展望

7.1 总结

本项目基于 MIT xv6-riscv，在保持原有体系结构稳定性的前提下，成功扩展并实现了 16 个新增系统调用。通过引入内核字节分配器、按需分页、写时复制、VMA 存储映射、FCFS 动态调度切换、轻量级线程、Futex 同步、符号链接等多项现代操作系统关键特性，进一步拓宽了系统的实际应用边界。

全量测试结果：alltests 集成测试 **PASS: 21/21**；grind 压力测试持续运行数十分钟，**系统稳定，未发生内核 Panic 或死锁。**

通过移植 LLM 推理引擎 llama.c 并设计三组对比实验，本项目进一步量化验证了：

- **多核并行能力：**RR 调度下 1 → 4 线程加速比达 1.84×。
- **Futex 同步优势：**相比 Spinlock 快 92.4%，相比 Pipe 快 40%。
- **mmap 零拷贝优势：**冷启动耗时 0 Ticks，对比 malloc+read 的 21 Ticks。

本项目已达到课程要求，具体工作：

- 基础环境搭建：构建远程 SSH 开发环境，完成交叉编译链和 QEMU 配置，通过 usertests 基础测试验证。
- 系统调用与异常防护：实现用户态异常分类拦截（非法指令、段错误）、getprocs 系统调用、内核动态内存分配器 kmalloc/kmfree，以及集成测试框架 alltests。
- 核心进程管理：实现 FCFS 与 RR 调度切换、waitpid 精准进程回收、基于 sleep/wakeup 的信号量机制，以及基于时钟中断的 alarm 异步事件通知。
- 文件系统增强：实现 lseek 文件定位和 symlink 软链接。
- 进阶虚拟内存管理：实现 Lazy Allocation（按需分页）、Copy-On-Write Fork（写时复制）以及 mmap/munmap（文件内存映射）。
- 多线程与用户态同步：基于独立页表 + 物理共享的 clone 轻量级线程模型，以及 futex 用户态快速同步锁。
- 简单的 LLM 推理引擎移植与性能评估：将 llama2.c 移植到 xv6，通过三个基准实验量化评估多核可扩展性、同步原语效率以及存储映射性能。

7.2 存在不足

- FCFS 两阶段扫描在释放进程锁与重新锁定的间隙存在同步窗口，会有额外开销。
- mmap 未完全实现零填充，存在物理内存历史脏数据泄露的隐患。
- clone 当前通过 filedup 复制文件描述符表，而非完全共享同一个文件描述符数组，与 POSIX 标准线程的文件共享语义存在差异。

- 少数情况下，运行 bench 实验时系统有偶发的卡死现象，初步定位该问题与 sys_futex 的慢速路径调度时序有关，或其他原因。

7.3 展望

- 实现多核负载均衡，改进 FCFS 调度器，引入每个核心的本地就绪队列，减少全局锁竞争。
- 扩展 clone 系统调用参数，支持线程间真正共享同一个描述符数组，提升 POSIX 兼容性。
- 进一步分析并修复实验程序偶发卡死的问题。
- 当前 kmalloc/kfree 基于 First-Fit 算法，可进一步实现更高效的 Buddy System 或 Slab Allocator。
- 实现 ProcFS 虚拟文件系统。
- 增加更多进程调度算法（SPF、优先级调度等）。
- 完善用户态 libc。
-

参考资料（部分）

- <https://github.com/mit-pdos/xv6-riscv>
- <https://github.com/mit-pdos/xv6-riscv-book/>
- <https://github.com/qemu/qemu>
- <https://github.com/sandyyyzy/Re-XVapor>
- <https://github.com/tianx666/xv6-book-riscv-rev1-Chinese>
- https://blog.csdn.net/zzy980511/category_11740137.html
- <https://github.com/mit-pdos/xv6-riscv-fall19>
- <https://github.com/torvalds/linux>
- <https://pdos.csail.mit.edu/6.S081>
- <https://linux-kernel-labs.github.io/>
- <https://pdos.csail.mit.edu/6.S081/2020/labs/lazy.html>
- <https://fail.lingfei.xyz/tags/xv6/>
- <https://github.com/karpathy/llama2.c>